

股票 Alpha 因子发掘系统 — 设计文档

日期: 2026-06-20 状态: 已批准, 待实现 作者: brainstorming 协作产出

1. 目标与定位

构建一套**巴菲特风格的低频价值投资**股票 Alpha 因子发掘系统, 面向**美股 S&P 500**, 月度/季度调仓。系统覆盖数据采集、处理、因子计算、因子评估、ML 多因子合成、策略回测, 并通过命令行输出排名股票清单与回测报告。

核心理念: 可解释的基本面价值因子打底, ML 仅用于因子加权/组合优化, 而非黑盒挖因子。先用免费数据源跑通原型, 后续再考虑升级。

2. 范围与约束

- 市场:** 美股, universe = S&P 500 当前成分股
- 频率:** 低频, 月度 (默认) 或季度调仓
- 数据源 (原型):** `yfinance` (价格 + 基本面字段); 后续升级路径为 SEC EDGAR companyfacts (更权威)
- 方法论:** 基本面因子 + LightGBM 多因子合成打分
- 交互:** CLI (命令行/脚本), 输出排名清单 + 回测报告
- 架构选型:** 轻量模块化管线 (best-of-breed 组合), 非 Qlib 一体化框架

已知局限 (原型阶段, 文档化)

- 幸存者偏差:** 原型使用当前 S&P 500 成分股, 未用历史成分股。标注为已知局限, 后续升级。
- 基本面数据质量:** `yfinance` 基本面字段不如官方财报权威, 原型可接受, 后续用 EDGAR 升级。

3. 架构与模块边界

6 个单一职责模块, 通过 `pandas DataFrame (MultiIndex(date, ticker))` + `parquet` 文件通信, 各自可独立测试。

alpha-studio/

data/数据采集与缓存层

pricesyfinance 拉日线 → parquet 缓存

fundamentalsyfinance 基本面字段 → 标准化 → parquet (升级位: SEC EDGAR)

universe维护 S&P 500 成分股列表

factors/因子计算层 (纯函数: 财报+价格 → 因子值 DataFrame)

evaluation/Alphalens 评估单因子有效性 (IC/IR、分组、换手率)

model/LightGBM 多因子合成打分 (cross-sectional, 月度)

backtest/月频调仓回测引擎 + 交易成本, pyfolio 出报告

cli/命令行入口, 串联流程

接口约定

- 各层输入/输出均为带 `MultiIndex(date, ticker)` 的 `pandas DataFrame`, 落地 `parquet`

- **data/** 层对上层屏蔽数据源差异——换付费 API 只改 **data/**，上层不动
- **factors/** 层每个因子是独立纯函数，便于单测与增删

设计原则

- 数据采集与因子计算解耦
- 因子定义与模型解耦（换因子不动模型，换模型不动因子）
- 模块小而聚焦，单一职责，接口清晰

4. 端到端数据流

1. universe

→ 取当前 S&P 500 成分股列表

2. data

→ 拉每只股票日线价格 + 季度财报字段，缓存 parquet

3. factors

→ 在每个调仓日（月末）计算每只股票的因子横截面

4. evaluation

→ （研究模式）Alphalens 看各因子 IC/IR，筛掉无效因子

5. model

→ LightGBM 用历史因子→未来1月收益训练，输出当期综合打分

6. backtest

→ 按打分选 Top-N、月度调仓、扣成本，pyfolio 出报告

7. cli

→ 打印当期排名清单 + 保存回测报告

5. 因子方法论

首批因子（巴菲特价值风格，可解释）

类别	因子
盈利能力	ROE、ROA、毛利率、净利率
估值	PE、PB、FCF Yield、EV/EBIT
质量	负债率（D/E）、流动比率、盈利稳定性
成长	营收增速、EPS 增速（温和成长，非高估值成长股）

防坑设计

- **Point-in-time / 滞后**：财报按发布日滞后使用（季报延后约 45–90 天），避免未来函数（look-ahead bias）
- **横截面标准化**：每个调仓日对因子做 z-score 或分位排名，再合成
- **缺失值处理**：财报缺失的股票当期剔除，不强行填充
- **幸存者偏差**：原型接受当前成分股偏差，文档标注

ML 部分（务实，防过拟合）

- 模型：LightGBM 回归，目标 = 未来 1 个月（或 3 个月）收益
- 标签与特征严格时间对齐，**walk-forward 训练**（过去训、未来测），不做随机划分
- 防过拟合：限制树深、特征数少、定期重训

6. 回测引擎（月频，自建薄层）

- 每月末按综合打分选 Top-N（如 Top 20–30 只），等权或按打分加权

- 交易成本：每次换仓扣手续费+滑点（如单边 0.1%）
- 输出指标：年化收益、夏普、最大回撤、胜率、换手率、与 S&P 500 基准对比
- 用 `pyfolio` 生成 tearsheet 报告（图 + 表）

7. CLI 命令设计

```
sp run-pipeline           # 全流程：拉数据→算因子→训练→回测→出报告
sp rank --date 2025-06    # 输出某月当期排名股票清单（实盘选股用）
sp fetch-data             # 仅更新数据缓存
sp eval-factors           # 仅跑 Alphascore 因子有效性诊断
sp backtest --start --end --topk  # 仅回测
```

8. 错误处理

- 数据层：单只股票拉取失败 → 记录日志跳过，不中断整体；网络重试
- 缓存：parquet 已存在则跳过重拉，支持增量更新
- 因子层：缺失数据当期剔除该股票并记录
- 全程结构化日志（loguru 或标准 logging）

9. 测试策略

- **因子函数**：小型构造数据单测，手算对比（如 ROE）
- **防未来函数**：专门测试财报滞后逻辑
- **回测引擎**：已知输入验证收益/调仓计算
- **数据层**：mock API 响应，不依赖真实网络
- 框架：pytest

10. 技术栈

- Python 3.11+, 依赖管理 `uv` 或 `pip + requirements.txt`
- 核心库：pandas、numpy、yfinance、lightgbm、alphalens-reloaded、pyfolio-reloaded、pyarrow、loguru、typer(CLI)
- 测试：pytest

11. 可复用开源工程（调研结论）

- **Alphascore (alphalens-reloaded)**：因子有效性诊断标准工具，直接用于 evaluation 层
- **pyfolio (pyfolio-reloaded)**：组合风险收益分析与 tearsheet，用于回测报告
- **LightGBM**：因子合成 ML 模型
- **yfinance**：原型数据源
- **Microsoft Qlib**：评估后未采用为骨架（美股免费基本面接入摩擦大、框架重、黑盒多）；保留为未来参考

12. 未来升级路径

1. 基本面数据源 yfinance → SEC EDGAR companyfacts（point-in-time、更权威）
2. 引入历史成分股，消除幸存者偏差

3. 评估升级数据源至付费 API（如 Financial Modeling Prep）
4. 可选：扩展 universe 至中小盘或全美股
5. 可选：Web 仪表盘